PRAKTIK NLP · PERTEMUAN 05 · S1 TEKNIK INFORMATIKA

Dari ulasan ke dataset yang siap diuji.

Label yang jelas. Data yang bersih. Pembagian yang dapat diulang.

Data contoh bersifat sintetis. Label ditentukan melalui anotasi manual. Hasil tersimpan pada peramban ini; unduh cadangan JSON sebelum berpindah perangkat. Aplikasi tidak mengirim anotasi ke server.

01 Anotasi 02 Kualitas 03 Representasi 04 Bukti

01 / Telaah dan anotasi

Pilih positif, negatif, atau netral; tentukan aspek dominan dan jelaskan bukti dalam teks. Ulasan campuran perlu keputusan yang dicatat.

Muat 60 data contoh

Impor dataset/cadangan JSON Choose File No file chosen

Unduh cadangan JSON

Pembagian dibuat. Vocabulary hanya berasal dari train.

ID / Teks	Label	Aspek	A
R001 · Pelayanan tidak bagus dan responsnya lambat.	negatif	pelayanan	
R002 · Notifikasi pesanan sering gagal muncul.	negatif	aplikasi	
R003 · Toko buka pukul delapan pagi.	netral	jam_operasional	
R004 · Pesanan datang terlambat dua jam.	negatif	pengiriman	
R005 · Pembayaran berlangsung lancar tanpa kendala.	positif	pembayaran	

02 / Audit dan pembagian data

60
total

30
positif

18
negatif

12
netral

0
belum_berlabel


```
{
  "tanpa_alasan": 0,
```

```
  "teks_kosong_setelah_normalisasi": [],
  "duplikat": []
}
```


Duplikasi setelah normalisasi diblokir agar tidak masuk ke subset berbeda. Pembagian dilakukan secara stratifikasi; persentase aktual dapat berbeda akibat pembulatan.

Seed 42

Bagi 70 : 15 : 15 dan pelajari TF-IDF


```
{
  "train": {
    "jumlah": 40,
    "persen": "66.7",
    "kelas": {
      "positif": 20,
      "negatif": 12,
      "netral": 8
    },
    "ids": [
      "R057",
      "R005",
      "R050",
      "R048",
      "R025",
      "R014",
      "R019",
      "R055",
      "R042",
      "R056",
      "R031",
      "R047",
      "R037",
      "R020",
      "R059",
      "R016",
      "R060",
      "R054",
      "R036",
      "R046",
      "R002",
      "R030",
      "R045",
```

```
      "R023",
      "R052",
      "R010",
      "R009",
      "R024",
      "R013",
      "R035",
      "R004",
      "R001",
      "R018",
      "R053",
      "R021",
      "R003",
      "R040",
      "R041",
      "R017",
      "R028"
    ]
  },
  "validation": {
    "jumlah": 10,
    "persen": "16.7",
    "kelas": {
      "positif": 5,
      "negatif": 3,
      "netral": 2
    },
    "ids": [
      "R007",
      "R043",
      "R049",
      "R033",
      "R027",
      "R044",
      "R012",
      "R006",
      "R029",
      "R026"
    ]
  },
  "test": {
    "jumlah": 10,
    "persen": "16.7",
    "kelas": {
      "positif": 5,
      "negatif": 3,
```

```
      "netral": 2
    },
    "ids": [
      "R039",
      "R032",
      "R008",
      "R034",
      "R058",
      "R022",
      "R015",
      "R051",
      "R038",
      "R011"
    ]
  },
  "bobot_kelas_train": {
    "positif": 0.6666666666666666,
    "negatif": 1.1111111111111112,
    "netral": 1.6666666666666667
  }
}
```


03 / Membaca representasi

Vocabulary dan IDF dipelajari hanya dari data latih. TF berupa jumlah token, IDF = ln((1+n)/(1+df))+1, kemudian normalisasi L2. Negasi dipertahankan; emoji belum direpresentasikan.

Kalimat A

Pelayanan tidak bagus

Kalimat B

Pelayanan bagus

Bandingkan TF-IDF

```
{
  "A": [
    {
      "term": "pelayanan",
      "weight": 0.6806019332977086
    },
    {
      "term": "bagus",
      "weight": 0.5632617703774219
    },
    {
      "term": "tidak",
      "weight": 0.4685266122886872
    }
  ],
  "B": [
    {
      "term": "pelayanan",
      "weight": 0.7703915423424527
    },
    {
      "term": "bagus",
      "weight": 0.637571071714532
    }
  ],
  "cosine": 0.8834493837098344,
  "catatan": "Token di luar vocabulary diabaikan. Vektor nol berarti tidak ada token yang dikenali. Kemiripan bukan prediksi sentimen."
}
```


▼ Bagaimana dengan embedding?

Embedding menggunakan model pralatih untuk menghasilkan vektor padat. TF-IDF bertumpu pada kecocokan token, sedangkan embedding dapat merepresentasikan kedekatan makna. Kemiripan bukan probabilitas sentimen. Praktik embedding nyata tersedia pada berkas docs/embedding_opsional.py; tidak ada vektor simulasi yang ditampilkan sebagai hasil model.

04 / Simpan bukti eksperimen

Perubahan anotasi membatalkan pembagian lama. Jalankan pembagian lagi sebelum ekspor paket eksperimen.

Unduh eksperimen JSON | Unduh dataset CSV

Tambahkan JSON, CSV, laporan, dan bukti pembagian ke repositori GitHub. URL Vercel menampilkan aplikasi; anotasi setiap peramban tetap terpisah.